北 京 邮 电 大 学

本科毕业设计（论文）中期进展情况检查表

<table>
<tr><td>学院</td><td colspan="2">计算机学院（国家示范性软件学院）</td><td>专业</td><td colspan="2">计算机科学与技术</td></tr>
<tr><td>学生姓名</td><td>武垚乐</td><td>学号</td><td>2022211319</td><td>班级</td><td>2022211309</td></tr>
<tr><td>指导教师姓名</td><td>张宇超</td><td>所在单位</td><td>计算机学院</td><td>职称</td><td>副教授</td></tr>
<tr><td rowspan="2">设计（论文）题目</td><td colspan="5">（中文）面向分布式推理的零知识证明框架设计与低开销优化</td></tr>
<tr><td colspan="5">（英文）Design and Low-Overhead Optimization of Zero-Knowledge Proof Framework for Distributed Inference</td></tr>
<tr><td>目前已完成任务</td><td colspan="5">一、课题研究背景与目标回顾
本课题围绕分布式推理场景下的计算可验证性问题展开研究。随着深度学习模型规模持续增长，单节点推理在算力、时延和吞吐方面面临明显约束，按层切分并部署到多个节点协同执行已成为提升推理可扩展性的重要方式。然而，在分布式环境下，各工作节点可能并非完全可信，传统日志记录和完整性校验难以充分保证推理结果的正确性。零知识证明（Zero-Knowledge Proof, ZKP）技术能够在不泄露计算细节的前提下证明计算满足既定电路约束，因此为分布式推理的可验证性提供了可行路径。

根据任务书要求，本课题的核心目标包括三项：第一，构建分布式推理原型系统，实现模型按层切分并在多个工作节点上协同完成推理；第二，引入零知识证明机制，为各切片推理过程提供可独立验证的正确性证明；第三，在保证验证能力的前提下研究低开销优化策略，尽可能降低证明生成与验证带来的额外成本。目前，原型系统、证明接入和主要实验评估均已完成，系统已形成可运行、可验证、可测量的研究原型。

二、已完成的主要工作
2.1 分布式推理验证原型系统的设计与实现
本课题已完成面向分布式推理场景的 Prover-Worker 原型系统设计与实现。系统总体采用协调节点与工作节点分离的架构：协调节点负责按切片顺序调度推理任务、收集各节点返回的证明产物并打包结果；工作节点负责执行局部子模型推理，并在本地生成对应切片的零知识证明。系统基于 FastAPI 构建服务接口，使用 PyTorch 定义模型，导出 ONNX 后由 onnxruntime 执行推理，使用 EZKL 生成与验证证明。

在信任模型上，工作节点与协调节点均不被默认信任，最终认证结论由独立验证方根据离线编译工件和 proof bundle 独立给出。该设计满足“工作节点负责证明、协调节点负责调度、验证方独立认证”的总体思路。</td></tr>
</table>

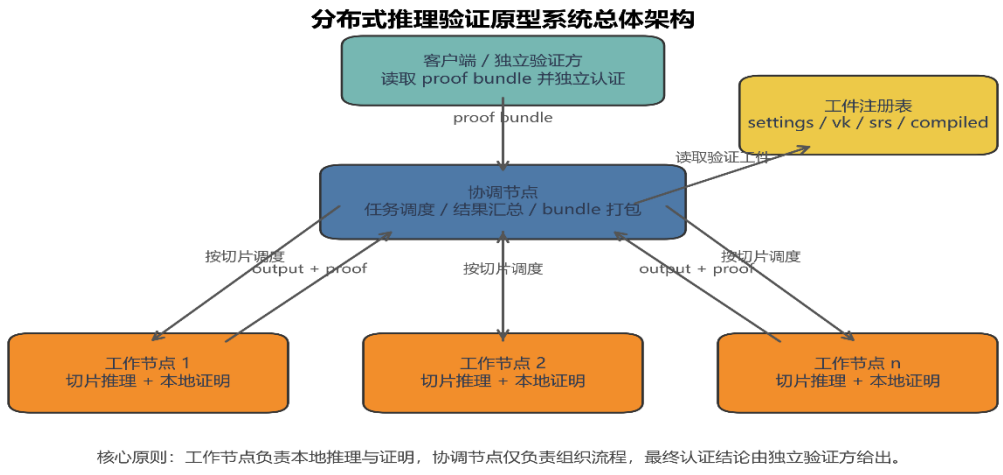

图 1 系统架构图

2.2 模型切分与多模型支持

当前系统已支持两类模型。第一类为 MNIST MLP，网络结构为 784→128→ReLU→64→ReLU→10，参数量为 109386，测试准确率约为 97.24%，支持 2、4、8 切片配置。第二类为 MNIST CNN，结构为 Conv2d(1→8, 3×3)→ReLU→Flatten→FC(5408→10)，参数量约为 54170，用于验证框架对卷积网络的适配能力。

目前，MLP 模型的 2 切片、4 切片和 8 切片配置均已完成端到端验证；CNN 模型的 2 切片配置也已完成正常路径和攻击路径实验。结果表明，本框架不仅适用于全连接模型，也能够支持包含卷积层的更复杂模型结构。

模型	网络结构	参数量	当前切片配置
MNIST MLP	784→128→ReLU→64→ReLU→10	109386	2 / 4 / 8
MNIST CNN	Conv2d(1→8, 3×3)→ReLU→Flatten→FC(5408→10)	约 54170	2

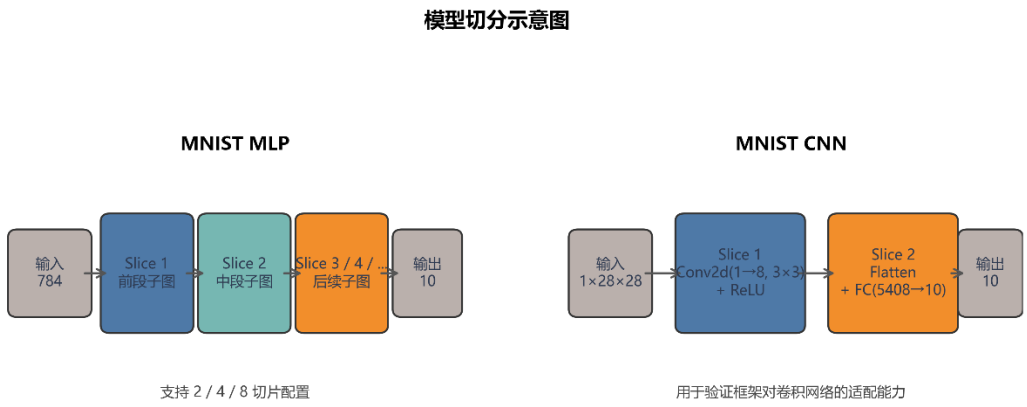

图 2 模型切片图

2.3 零知识证明接入、验证流程与 proof-bound output 机制

系统当前接入的零知识证明后端为 EZKL 23.0.5。该引擎基于 Halo2 算术电路、PLONK 证明系统与 KZG 多项式承诺方案，能够将 ONNX 推理图转换为可证明电路，并生成相应证明。

在验证流程方面，验证方需要依次完成单片 proof 校验、模型摘要绑定、跨切片链接检查以及终端一致性检查。只有当全部检查通过时，才判定整条推理链可被认证。

在此基础上，系统实现了 proof-bound output 机制。工作节点直接从 proof 的公开实例中提取 rescaled_outputs 作为可认证输出，验证方再从 proof 中独立提取同一输出并进行交叉比对，同时将 proof 绑定的输出作为下游切片输入。该机制避免了“proof 有效但返回输出被替换”的风险。

2.4 三阶段编译管线与链接精度结论

为解决相邻切片独立量化校准所带来的接口误差问题，系统实现了“三阶段编译管线”，即独立校准、接口 scale 对齐和统一编译。通过该流程，public 模式下的链接阈值能够收紧至约 2 ULP，对应量级约为 1/512，为跨切片链接验证提供了稳定基础。

围绕跨切片状态链接问题，当前已对 public、hashed 和 polycommit 三类方案进行了实验验证。结果表明：public 模式结合 scale 对齐后可以稳定工作；hashed 模式与 polycommit 模式在当前 EZKL 23.0.5 版本下均不可行，根因在于独立电路之间的接口 witness 不满足 bit-exact 一致性。因此，当前系统采用“public 模式 + scale 对齐 + 近似比较”作为工程可用方案，同时在论文中明确说明其边界条件。

在隐私保护方面，系统已实现应用层中间值过滤机制，可移除非首尾切片的中间量化值；但电路层面的承诺隐藏尚未落地，需要在后续的工作中寻找解决方法并且完成。

方案	当前结论	主要原因
public + scale 对齐	可用	接口误差可控制在阈值范围内
hashed + scale 对齐	不可行	接口 witness 不 bit-exact，哈希值不一致
polycommit	不可行	接口 witness 不 bit-exact，承诺结果不一致

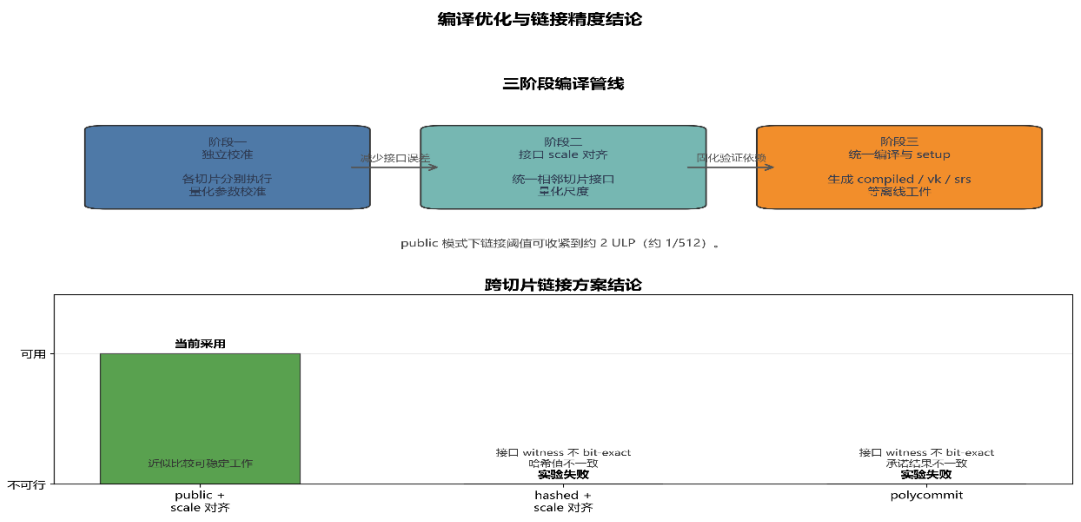

图 3 链接方案对比图

2.5 主要实验结果

按照任务书要求，本课题已完成证明生成时间、验证时间、推理延迟、节点 CPU / 内存占用率、系统吞吐量以及恶意节点检测准确率等关键指标的采集。

在 2、4、8 切片配置下，当前核心性能数据如下表所示。

切片数	证明总耗时 / ms	客户端验证时间 / ms	端到端总时延 / ms
2	7356.10	173.51	7844.66
4	19175.86	438.13	20288.84
8	32076.20	518.41	33559.44

结果表明，证明生成是系统的主要性能瓶颈，且随着切片数增加呈明显上升趋势；相比之下，客户端验证时间始终保持在较低水平。

在资源消耗方面，2 切片实验中协调节点 CPU 均值约为 4.95%，RSS 峰值约为 39.52 MB；工作节点 1 的 CPU 均值约为 289.09%，RSS 峰值约为 627.42 MB；工作节点 2 的 CPU 均值约为 245.23%，RSS 峰值约为 695.50 MB。当前 2 切片串行模式下实测吞吐量约为 0.1291 req/s。

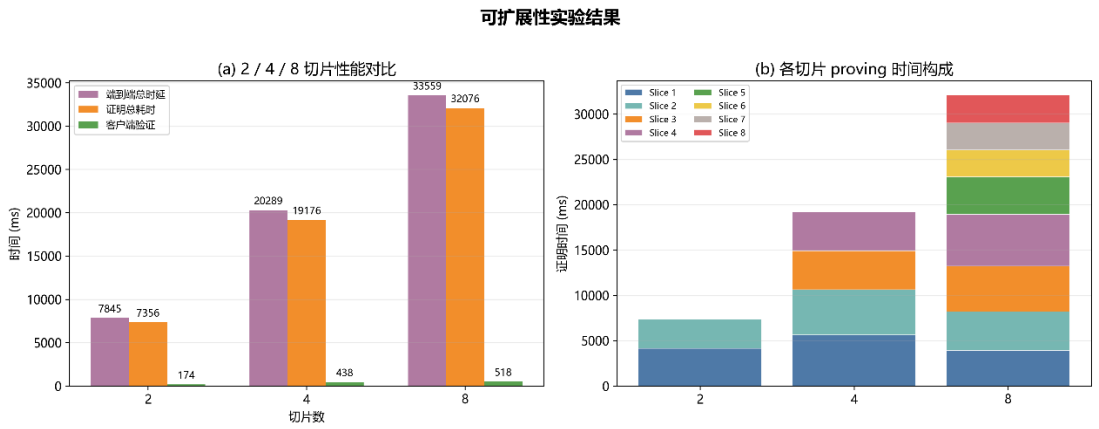

图 4 切片性能对比图

2.6 攻击检测、保真度与跨架构验证

在攻击检测实验中，系统已覆盖正常路径、末端篡改、末端跳过、随机替换、固定回放和中间切片篡改等场景。在当前实验设置下，独立验证流程能够稳定识别相关攻击，恶意节点检测准确率达到 100%，对应 Accuracy、Precision、Recall 和 F1-score 均为 1.0。

在保真度实验方面，F1 指标结果为 0，表明模型切分本身不引入误差；F2 指标中两片配置下最大绝对误差均值约为 0.0033 和 0.0020；F3 指标中端到端认证输出相对完整浮点模型的最大绝对误差均值约为 0.0020，认证通过率为 100%。这表明当前误差主要来自量化电路近似，而非切片方案本身。

在 CNN 跨架构验证方面，2 切片条件下 normal、tamper_last、skip_last 三组关键场景均得到与预期一致的结论，说明当前框架对卷积网络同样具有适用性。

CNN 场景	预期	实际	端到端总时延 / ms
normal	certified	certified	24444.82
tamper_last	invalid	invalid	22947.96
skip_last	invalid	invalid	19647.62

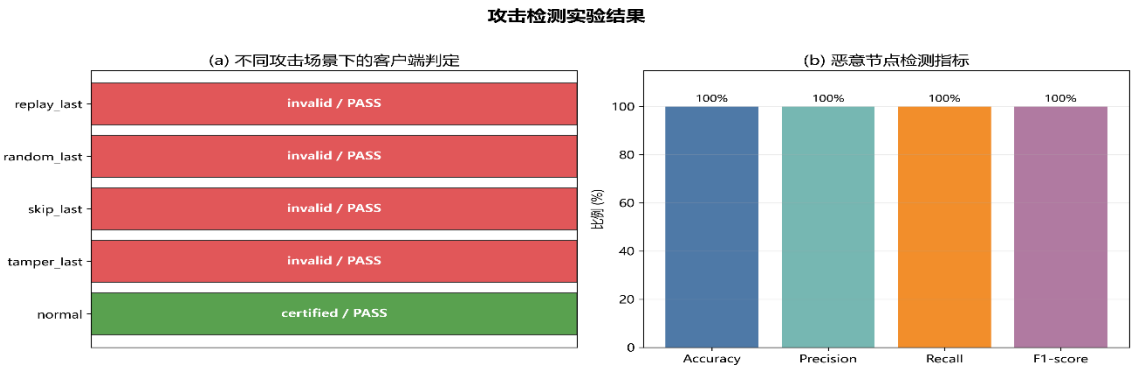

图 5 攻击检测结果图

2.7 测试与代码质量保障

当前项目已建立覆盖核心验证语义的自动化测试集合。测试内容包括请求隔离、缓存机制、proof-bound output 绑定、独立验证逻辑以及 proof bytes 相关诊断行为。当前测试总数为 32 项，全部通过，说明系统关键逻辑在当前代码版本下保持一致性与可回归性。

三、当前存在的问题

1. 证明生成开销仍然较高。 当前系统中，证明生成时间占端到端时延的比例较高，仍是主要性能瓶颈。
2. 精确链接在当前 EZKL 版本下尚不可实现。 hashed 模式与 polycommit 模式均已验证为不可行，当前只能采用近似比较方案。
3. 电路层隐私保护尚未完全落地。 当前实现的是应用层中间值过滤，而非真正意义上的电路级隐藏。
4. 部署环境仍以单机多进程通信为主。 当前主要实验仍在单机环境下完成，尚未完成多物理机实网验证。
5. 论文正文仍有部分章节待完成。 当前系统设计、实验评估和关键结论已明确，但绪论、相关工作、安全分析与总结展望等部分仍需继续整理。

四、下一步工作计划

近期工作的重点将放在论文正文撰写与结果整理上。首先，围绕当前已明确的系统实现与实验结论，完成绪论、相关工作、系统设计、实验评估和安全分析等章节的撰写；其次，对 exact linking 相关实验结果进行统一表述，明确区分当前工程可行方案与未来可能的密码学改进方案；最后，继续整理关键实验图表，使其能够直接用于论文和答辩材料。

在后续阶段，拟视实验条件补充多机环境下的并行 proving 测试，以验证流水线架构在真实分布式场景中的收益，同时完善相关工作与系统局限性分析。

五、总结

截至当前阶段，本课题已完成分布式推理验证原型系统的总体设计与主要功能实现，成功接入 EZKL 零知识证明引擎，构建了面向多切片场景的离线编译、在线推理和独立验证流程；实现了 proof-bound output 机制、scale 对齐编译管线以及推理与证明分离的流水线架构；完成了 2 / 4 / 8 切片可扩展性实验、F1 / F2 / F3 保真度实验、工作节点资源监控、CNN 跨架构验证和多类攻击检测实验，并对 public、hashed、polycommit 三类链接方案进行了系统性验证。

当前研究已经形成可运行、可验证、可测量的研究原型，并且对系统的可行路径与已知限制均已获得较为明确的实验结论。后续工作将主要围绕论文撰写、结果归纳和系统边界论证展开，在保持结论严谨性的前提下完成毕业设计的最终收束。

是否符合任务书要求进度	是 □	否 □

<table>
<tr><td rowspan="2">尚需完成的任务</td><td colspan="3">后续尚需完成的工作主要包括以下几个方面：
一是继续完成毕业论文正文撰写，重点补充绪论、相关工作、安全分析、总结与展望等章节，并对现有系统设计与实验评估部分进行统一整理；
二是对已有实验结果和图表进行进一步规范化处理，使其能够直接用于论文正文和答辩材料；
三是结合时间与实验条件，视情况补充多机环境下的并行 proving 测试，以进一步验证流水线架构在真实分布式场景中的收益；
四是完成中期后论文修改、终稿整理及答辩展示材料准备。</td></tr>
<tr><td colspan="3">是否可以按期完成设计（论文）　　☐是　　☐否</td></tr>
<tr><td rowspan="2">存在问题和解决办法</td><td>存在问题</td><td colspan="2">目前主要存在以下几个问题：
第一，零知识证明生成开销仍然较高，证明阶段仍是系统端到端时延的主要瓶颈；
第二，当前 EZKL 23.0.5 版本下，基于 hashed 模式和 polycommit 模式的跨切片精确链接尚未实现，当前工程方案仍需采用 public 模式下的 scale 对齐与近似比较；
第三，电路层面的承诺隐藏尚未落地，当前实现的隐私保护主要停留在应用层中间值过滤；
第四，系统当前仍以单机多进程实验为主，多物理机实网环境下的进一步验证仍待补充；
第五，论文部分章节和最终答辩材料尚需继续整理完善。</td></tr>
<tr><td>拟采取的办法</td><td colspan="2">针对上述问题，拟采取以下措施：
第一，继续以当前已经验证可行的 public + scale 对齐 + 近似比较方案作为论文中的已实现主线，对 hashed 和 polycommit 路线的失败原因进行如实分析，并作为系统局限性和后续工作进行讨论；
第二，优先完成论文正文撰写与实验图表整理工作，确保现有研究结果得到系统、准确和规范的表达；
第三，在后续时间允许的条件下补充多机环境下的并行 proving 实验，以增强系统评估的完整性；
第四，结合导师意见持续修改论文和答辩材料，确保按期完成毕业设计各项要求。</td></tr>
<tr><td colspan="2">指导教师签字</td><td>日期</td><td>年　月　日</td></tr>
<tr><td colspan="2">检查小组评分及意见</td><td colspan="2">评分：　　（总分：25）

组长签字：　　年　月　日</td></tr>
</table>